

Anima Model Editor (v2.0) 設計仕様書

高度モデル統合・レイヤー構造分析プラットフォーム

1. 開発概要・システム要件

1.1 ツール概要

本ツールは、画像生成モデル「Anima v1」およびその後継系統のモデル、ならびにその派生元である「Cosmos-Predict2-2B-Text2Image」を対象とする、モデルマージ、LoRAマージ、および内部レイヤー情報の可視化・分析を行うための高度な編集プラットフォームである。詳細なパラメータ調整と自動補正機能により、モデル崩壊を防ぎつつ直感的なモデルカスタマイズを実現する。

1.2 想定環境 (Target Environment)

- **CUDA:** 12.8 (cu128)
- **Python:** 3.12
- **Framework:** PyTorch 2.8 (torch2.8)
- **Optimization:** register_forward_hook による情報抽出、SVDによるランク圧縮、メモリ効率化

1.3 ライセンス・ガードレール (License Guardrail)

本ツールが扱うモデルが「Cosmos-Predict2-2B-Text2Image」の派生モデル (Derivative Model) を構成する場合、NVIDIA Open Model License Agreementの制約がマージ後のモデルにも適用される。

- **自動メタデータ付与:** モデル読み込み時およびマージ出力時、SafetensorsのHeader内metadataへ該当ライセンスの適用有無を自動書き込みする。
- **ライセンスアラート:** 該当モデルがロードされた際、GUI上にライセンス警告を常時表示する。

2. ディレクトリ構造とファイルガードレール

2.1 ディレクトリ構成 (Directory Structure)

プロジェクトルート直下に以下のフォルダ群を強制配置・運用する。

```
root/
├─ app/                # GUIソースコード、バックエンド処理ロジック
├─ checkpoints/        # 本体モデル配置 (Anima v1, Cosmos-Predict2-2B-Text2Image等)
├─ lora/               # LoRAモデル配置 (.safetensors)
├─ log/
│   └─ log_analysis/   # 分析結果テキスト (モデル名_分析手段.txt)
└─ configs/            # パラメータ設定プリセット (JSON/YAML)
```

2.2 ファイル読み込みガードレール (File Input Validation)

- **拡張子フィルタ:** プルダウンおよびエクスプローラー選択時、`.safetensors`、`.ckpt`、`.bin` 以外の入力を遮断。
- **アーキテクチャ検証:** モデルロード時にヘッダー (Header) を先読みし、ネットワークトポロジーやテンソル形状、ベースアーキテクチャの一致を確認。不一致時はロードを中断し、エラーログを出力。
- **ログファイル整合性検証:** 分析ログ (`.txt`) の冒頭に、生成時のモデル名、ハッシュ値、日時、分析範囲のメタデータ行を必須化。フォーマット不一致時は読み込みを拒否。

3. GUI構造およびコンポーネント定義

GUI全体は、上位に共通システムエリアを配し、メイン領域を4つの大タブ、および各タブ配下の内タブ (Sub-tab) で構成する。

3.1 共通システムエリア (Global System Area)

- **デバイス切り替え:** CPUモード / GPUモード の動的トグルスイッチ。
- **メモリ管理パネル (Memory Lifecycle Manager):**
 - 現在VRAM/RAMにロードされ、保持されているオブジェクト (モデル名、LoRA名、レポート名) を一覧可視化。
 - 手動でのロード (Load) およびアンロード (Unload / `torch.cuda.empty_cache()` 実行) ボタンを配置。
- **プリセット管理:** 設定値 (マージ比率、Alpha、閾値等) を `configs/` へJSON/YAML形式で保存・読み込みを行うプルダウンメニュー。
- **ファイル選択:** 各種モデル、LoRA、ログレポート類は、該当フォルダ内を自動スキャンしたプルダウン形式で選択。

3.2 タブ1：本体マージ (Model Merge)

本体モデルのU-Net/Transformerブロック (CLIP、VAEを除く) を対象とする。全レイヤー指定、詳細パラメータ、自動補正が適用可能。

- **内タブ1-1：本体同士をマージ (Model-to-Model Merge)**
- **内タブ1-2：LoRAを本体へマージ (LoRA-to-Model Merge / Fusing)**

3.3 タブ2：LoRAマージ (LoRA Merge)

- **内タブ2-1：LoRA同士をマージ (LoRA-to-LoRA Merge)**
- **内タブ2-2：本体差分からのLoRA抽出 (Model Subtraction)**

※制約: ターゲットモデルとベースモデルの階層構造およびチャンネル数が完全一致していることをロード時に検証。非対称な場合は例外処理 (エラーハンドリング) を実行。

3.4 タブ3：レイヤー分析 (Layer Analysis)

本体モデルまたはLoRAを読み込ませ、指定方式で全体/指定範囲を分析する。RAM/VRAM負荷軽減のため、レイヤーごとに段階的に分析を行う（段階的分析スケジューラー）。

- 内タブ3-1：特徴マップ可視化
- 内タブ3-2：統計的分析
- 内タブ3-3：SVDランク分析
- 内タブ3-4：アテンションマップ抽出

3.5 タブ4：詳細分析 (Detailed Analysis)

- 内タブ4-1：分析プレビュー (Analysis Preview): `log_analysis/` 内のテキスト形式の数値を参照し、レイヤー分析画面と同様のレポート・グラフ構成でいつでも閲覧・見返しができる機能。
- 内タブ4-2：レポート比較 (Report Comparison): 同一の分析方法を実行した、異なる（または同一の）モデル/LoRAのテキストログを2つ読み込み、近似値等を計算して可視化・比較する。

4. マージ制御パラメータ・自動補正アルゴリズム

すべてのマージ機能において、以下のパラメータ調整および自動補正が階層（レイヤー）ごとに独立して、または一括で適用できるものとする。

4.1 自動補正アルゴリズム (Auto-Correction)

マージによるモデル崩壊（生成画像の破綻）を防止するための動的制御。

- **Cosine Similarity Threshold:** パラメータの方向性が一定以上（閾値以下に）乖離している場合、マージ比率を自動減衰させ、整合性を維持する。
- **Bias Toggle:** $y = Wx + b$ におけるバイアス項をマージ対象から除外・固定する選択機能。色調や露出の安定化に寄与。
※拡張要件: 全層一括だけでなく、階層別（Input / Middle / Output ブロックごと）に独立してバイアス固定トグルを設定可能とする。

4.2 調整パラメータ属性 (Merge Parameters)

- **Alpha (Scaling Factor):** 各層の反映強度（手動・半自動設定）。LoRAマージ時は、SVDを用いてランクを再計算しノイズを最適化する `Rank-Based Merging`、およびレイヤー個別の `Alpha Scaling`、適用層を選択する `Module Filtering` を含む。
- **Frequency-based Merge:** FFT（高速フーリエ変換）等を用い、周波数領域（構図＝低周波、詳細＝高周波）ごとにマージ比率を制御。
- **Residual Connection Scaling:** スキップ接続の加算比率調整によるテクスチャ密度の制御。

4.3 マージ階層カテゴリ（適用単位選択）

カテゴリ	対象・役割
Block Merge	Input / Output / Middle Blocks等の階層別マージ
Component Merge	Attention (Self/Cross), MLP, Head層の個別比率調整
Feature Merge	Normalization (LayerNorm/GroupNorm), ResNetブロックの統合
Tensor/Spatial	Tensor形状、空間解像度ごとの重み調整
Temporal Merge	Timestep Embeddings（ノイズ除去段階）に応じた影響力制御

5. 分析データの可視化・レポート出力仕様

分析結果は `log/log_analysis/` フォルダへ `[モデル名]_[分析手段].txt` の命名規則で数値を保存する。GUI上では、数値だけでなく直感的にモデルの特徴を捉えられるレポート形式およびグラフで出力表示を行う。

5.1 各分析手段のログ保存およびGUI可視化形式

分析種別	ログ保存形式（txt）	GUI上の可視化・レポート形式
特徴マップ可視化	レイヤーごとの活性化状態の平均値、分散、空間的複雑度の数値マトリクス。	「テクスチャ・構図寄与度グラフ」 低層・中層・高層の活性化傾向から算出された「形状重視度」「ディテール重視度」の比率をレーダーチャートで表示。
統計的分析	レイヤーごとのL2ノルム、平均値、分散の階層順リスト。	「エネルギー分布プロファイル」 横軸をレイヤーインデックス、縦軸をL2ノルム（重みのエネルギー）とした折れ線グラフ。過学習やモデル崩壊の兆候を示す異常値レイヤーを自動的にハイライト警告。
SVDランク分析	特異値の減衰率、累積寄与率、有効ランク数のリスト。	「情報冗長度・キャパシティバー」 各レイヤーの情報保持の飽和状態を帯グラフ（カラーバー）で表現。情報が密集している層（圧縮不可）と、冗長で削っても影響が少ない層を視覚的に色分け。
アテンションマップ抽出	代表的なプロンプトカテゴリ（構図、色彩、キャラクター、背景等）に対する、トークンごとのアテンションウェイト分布。	「プロンプト感度ヒートマップ」 プロンプト要素がどのブロック（Input / Middle / Output）に強く反映されているかをマトリクス状のヒートマップで視覚化。

5.2 ルールベースによる特徴自動レポート生成 (Automated Text Reporting)

パラメータや分析ログの数値傾向から、モデルの特徴・マージ時の競合予測をテキストで自動出力する。

- **判定パターンA（学習の偏りと競合予測）：**

トリガー条件: Middle BlockのL2ノルムおよびSVD有効ランクが他ブロックに比べ有意に高い。

出力テキスト: 「本モデル/LoRAは構図・オブジェクト配置 (Middle Block) に学習が偏っています。スタイルやテクスチャを司るInput/Output Blockへの影響は軽微であるため、画風特化型モデル/LoRAとマージする際の競合リスクは低いです。」

- **判定パターンB（モデル崩壊の危険性予測）：**

トリガー条件: 主要なSelf-Attention層における2モデル間のCosine Similarityが、設定閾値（デフォルト: 0.4）を下回っている。

出力テキスト: 「対象モデル間で特定のAttention層の方向性が大きく乖離しています。そのままマージすると構造の破綻（モデル崩壊）を招く高リスクがあります。『Cosine Similarity Threshold』の自動減衰機能を有効にするか、該当層のマージ比率を0.3以下に下げることが推奨します。」

5.3 レポート比較（詳細分析）の仕様

- **比較演算:** 2つのログファイルから同一レイヤーの数値を走査し、コサイン類似度および差分比率を算出。
- **差分ハイライトチャート:** 2つのモデルの統計線グラフを重ね合わせ表示し、乖離度（ユークリッド距離）が大きいレイヤー区間を赤色でハイライト。
- **近似度スコア:** 構造類似度、色彩・階層類似度などの多角的な項目別スコアを算出し、総合近似度（0～100%）を数値出力。

6. バックエンド処理・最適化仕様

6.1 段階的分析スケジューラー (Sequential Layer Analysis Scheduler)

メモリ（RAM/VRAM）のオーバーフローを防ぐため、全レイヤーの一括処理を禁止する。

- **イテレータ制御:** レイヤーインデックスごとにループを回し、1レイヤー分の前方向不連続フック（forward hook）処理が完了するごとにデータをCPU側へ退避。
- **キャッシュ解放:** 各ステップの終了時に、明示的に `torch.cuda.empty_cache()` および Pythonの `gc.collect()` を実行する。
- **進捗シグナル:** GUI側へ「現在第 N 層を分析中（VRAM消費量: X GB）」のステータスシグナルをリアルタイム送信する。

6.2 マージ前簡易プレビュー (Dry-Run Test)

ディスクへの巨大なモデルファイル書き込みによる時間的ロスを防ぐための検証機能。

- **ダミーターゲット実行:** マージ適用後のネットワークに対し、ランダムなノイズテンソルを1ステップのみ通す。

- **異常検知:** 出力テンソル内の NaN（非数）または Inf（無限大）の発生有無、および出力統計量が正常範囲内にあるかを検証。異常検知時はディスク書き込み処理を強制停止し、該当レイヤーの設定再考をユーザーに促す。